



# **Classificação do comportamento do gado leiteiro usando dados de sensores de movimentos com redes Multilayer Perceptron**

Aluno: Anderson Santos

Professor: Valmir Marcario Filho

Disciplina: Redes Neurais



# Ementa

Introdução

Base de dados

Visualização dos dados

Arquitetura

Resultados

Trabalhos futuros



# Introdução

Pecuária de precisão

Análise dos comportamentos

Sensores



## Base de dados





## Base de dados

2 períodos: o primeiro de 25/03/15 a 30/03/15. O segundo de 06/04/15 a 09/04/15.

Foram utilizadas 4 coleiras (A, B, C e D). Entretanto, houve algumas falhas durante o experimento e, no final, ficaram as seguintes bases:

- A2 e A3
- B2 e B3
- C3 e C4
- D1, D2, D3 e D4

Sensores: acelerômetro, giroscópio e magnetômetro.

As coletas foram feitas na frequência de 1 Hz.



## Base de dados

Os dados foram armazenados em um cartão SD para posteriormente serem carregados e processados.

Classes dos comportamentos: pastando, andando, em pé e deitado.

**Pastando:** caracterizado pelo animal sobre as quatro patas, com a cabeça baixa procurando ou mastigando o capim. O animal pode ou não estar em movimento, já que ele pode estar se deslocando à procura de capim;

**Andando:** o animal também está sobre as quatro patas, porém com o pescoço reto (apontando o focinho para frente) e se deslocando pela área de pasto;

**Em Pé:** o animal está sobre as quatro patas, com a cabeça erguida e não há deslocamento;

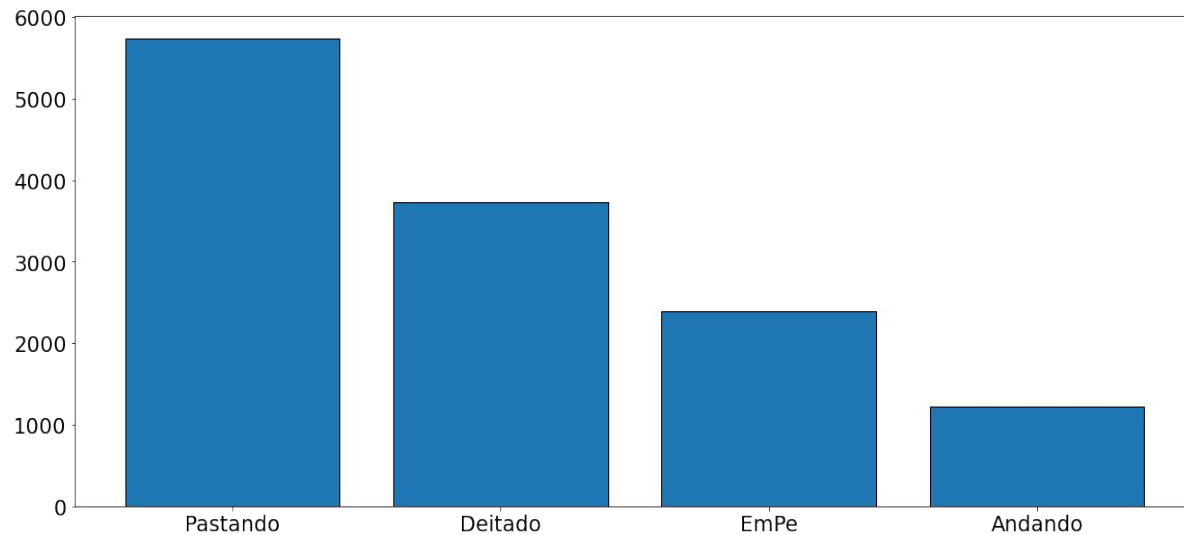
**Deitado:** o animal está com as patas abaixadas e com a barriga tocando o solo.

---

# Visualização dos Dados

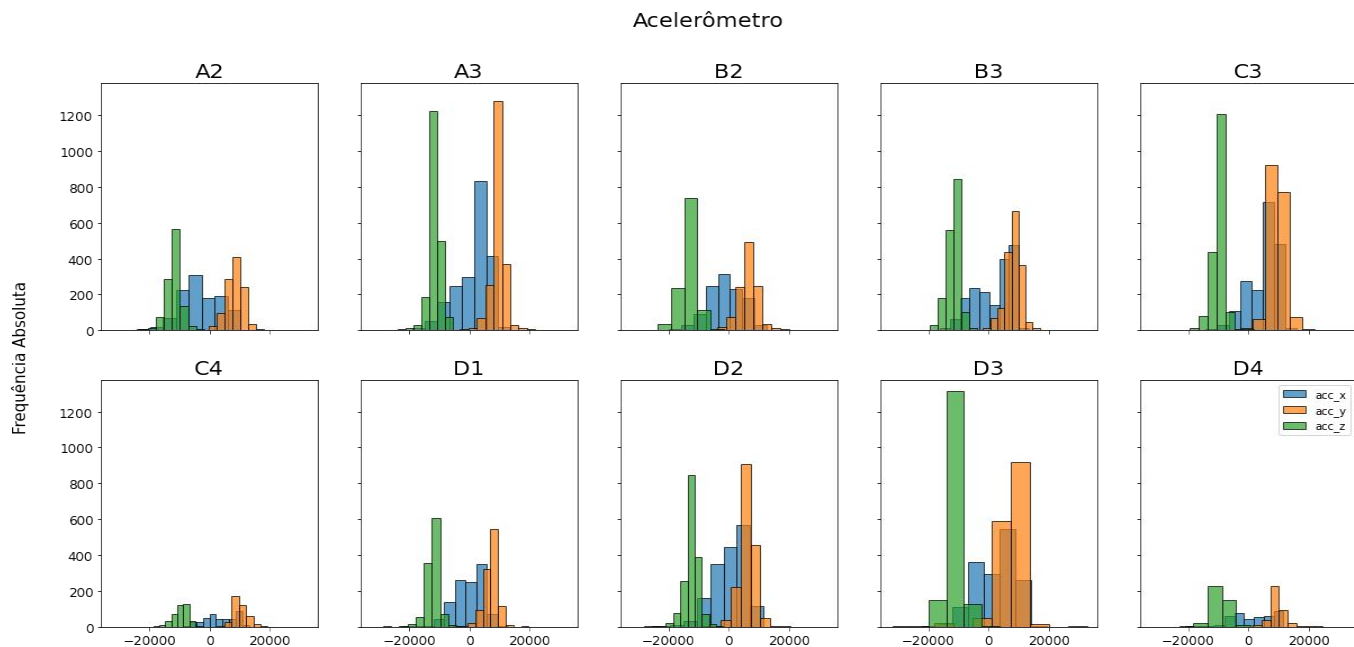


## Histograma das classes

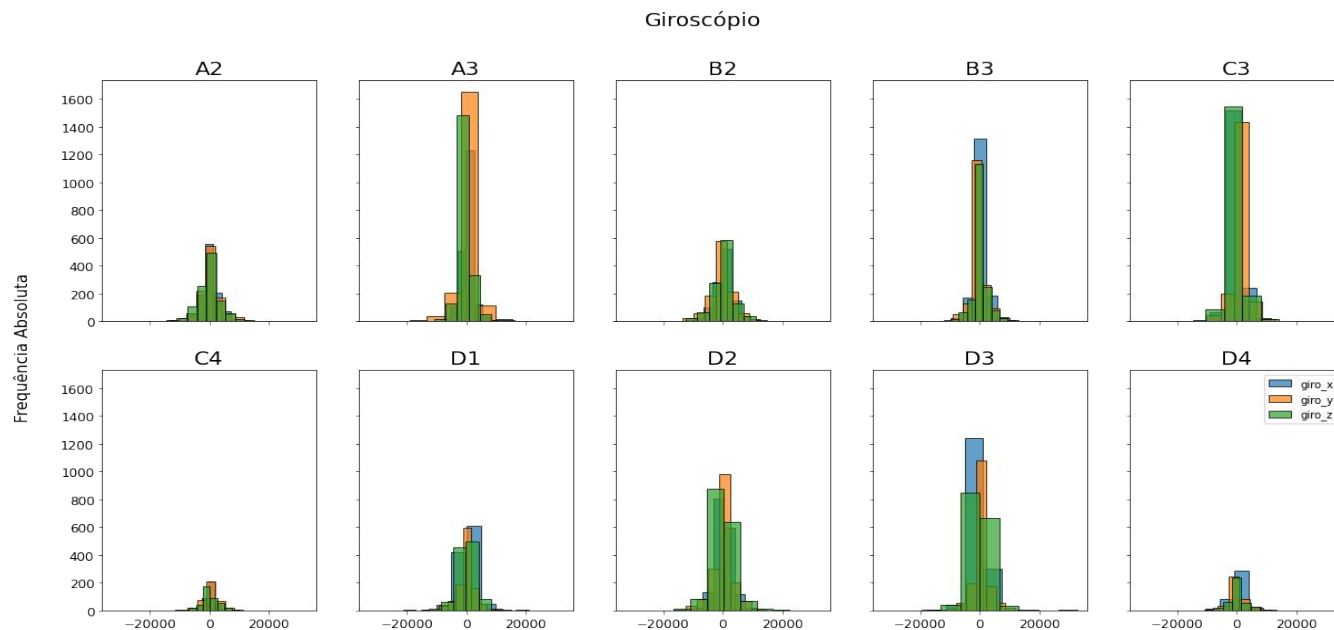




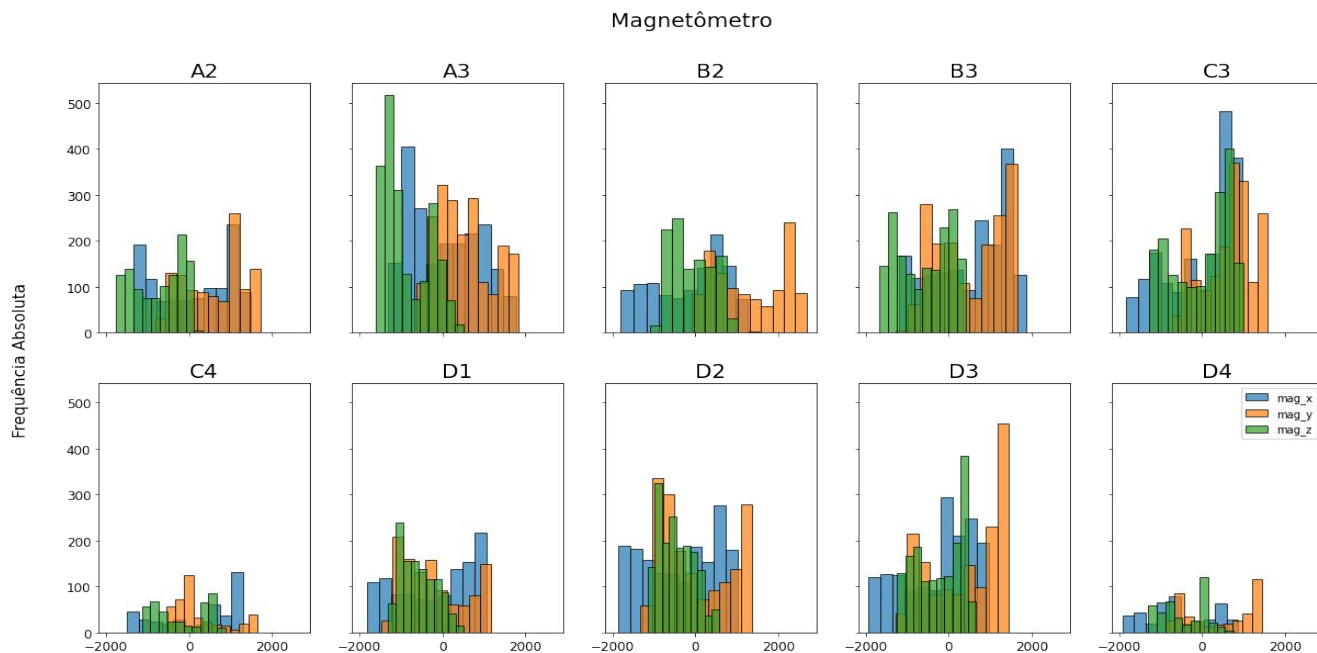
# Histogramas dos sensores por coleira



# Histogramas dos sensores por coleira

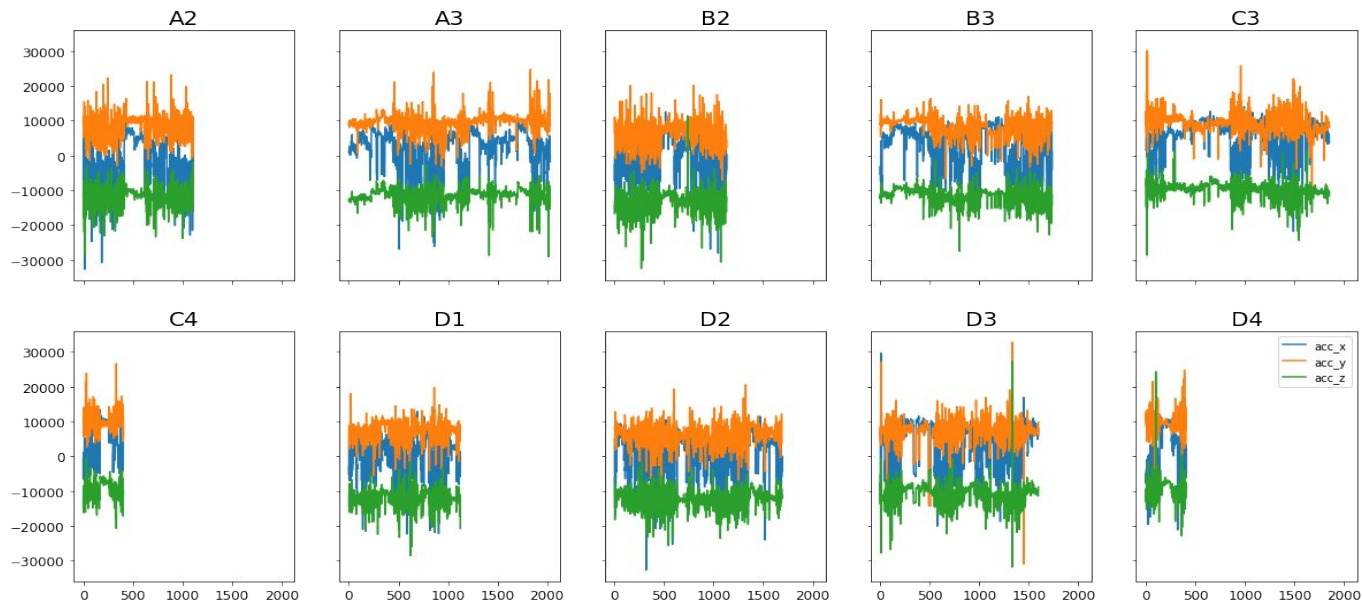


# Histogramas dos sensores por coleira



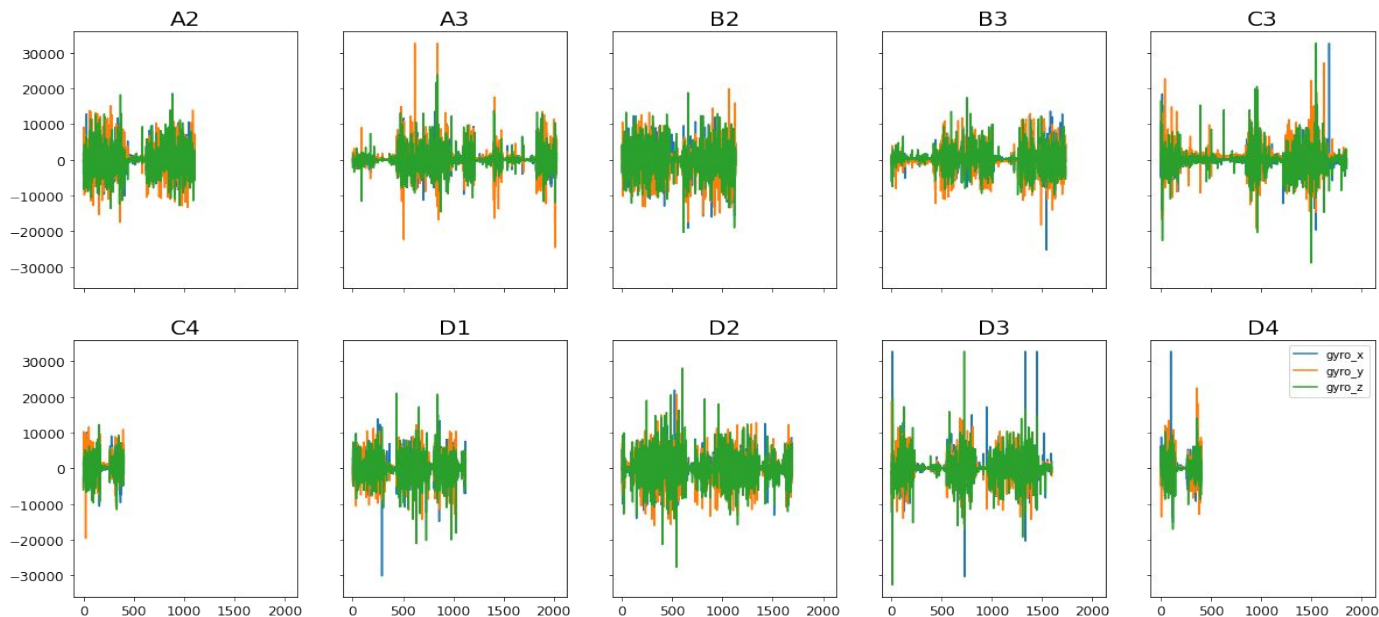
# Séries Temporais dos sensores por coleira

Acelerômetro



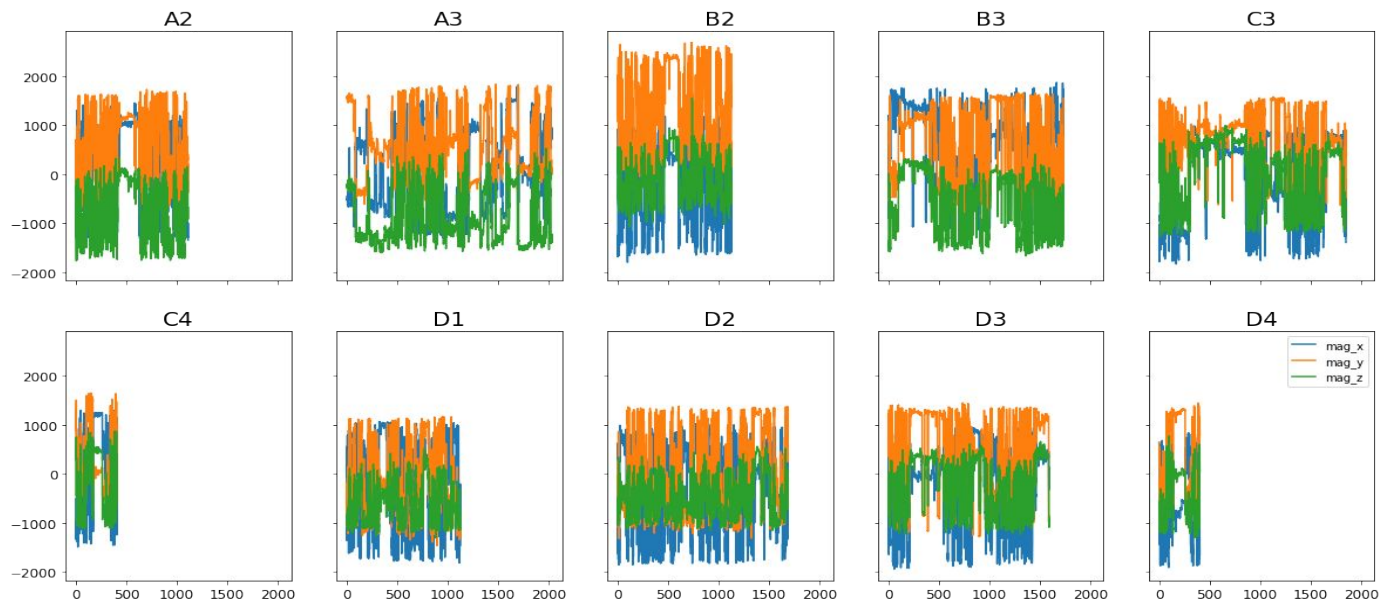
# Séries Temporais dos sensores por coleira

Giroscópio




# Séries Temporais dos sensores por coleira

Magnetômetro



# Arquitetura



- I. Função de ativação: regressão logística (sigmóide)
- II. Algoritmo de otimização: gradiente descendente
- III. Termo de regularização L2: 0.0001
- IV. Atualização dos pesos em lotes com tamanho de 24 amostras
- V. Taxa de aprendizagem: 0.3
- VI. Número de épocas: 200
- VII. Randomização das amostras para cada iteração
- VIII. Momentum: 0.9

# Validação

Base de Dados										
Treinamento							Validação			
n=1	F1	F2	F3	F4	F5	F6	F7	F8	F9	F10
n=2	F1	F2	F3	F4	F5	F6	F7	F8	F9	F10
n=3	F1	F2	F3	F4	F5	F6	F7	F8	F9	F10
n=4	F1	F2	F3	F4	F5	F6	F7	F8	F9	F10
n=5	F1	F2	F3	F4	F5	F6	F7	F8	F9	F10
n=6	F1	F2	F3	F4	F5	F6	F7	F8	F9	F10
n=7	F1	F2	F3	F4	F5	F6	F7	F8	F9	F10
n=8	F1	F2	F3	F4	F5	F6	F7	F8	F9	F10
n=9	F1	F2	F3	F4	F5	F6	F7	F8	F9	F10
n=10	F1	F2	F3	F4	F5	F6	F7	F8	F9	F10

Acurácia Média





## Resultados

1º nível	2º nível	Acurácia (%)
9	6	41.66 (0.0674)
18	8	40.89 (0.0676)
27	10	44.22 (0.0149)
36	12	44.55 (0.0642)

Sem normalização

1º nível	2º nível	Acurácia (%)
9	6	76.32 (0.0707)
18	8	76.25 (0.0728)
27	10	77.82 (0.0531)
36	12	78.03 (0.0597)

Com normalização



## Trabalhos Futuros

- Aumentar a quantidade de neurônios na camada intermediária e verificar a resposta da rede em relação à acurácia e a presença de overfitting;
- Aplicar um pré-processamento nos dados;
- Aumentar a quantidade de épocas no treinamento;
- Utilizar uma abordagem evolucionária para obter os melhores parâmetros da rede;
- Testar outros algoritmos além do gradiente descendente como o LBFGS e ADAM;
- Utilizar outras funções de ativação como por exemplo a tangente hiperbólica, Relu, Elu e entre outras

**FIM**

—